Clasificación de imágenes de perros y gatos

MobileNetV2 como modelo de producción y CNN académica comparativa

Informe generado automáticamente el 2026-10-19 14:57

Todas las métricas provienen de los artefactos reales del proyecto.

Este documento describe la arquitectura, el proceso de entrenamiento, los experimentos comparativos y la evaluación del modelo. Las cifras se obtuvieron de **reports/metrics.json**, **reports/training_history.json**, **reports/experiments.csv** y **reports/data_quality.json**.

1. Resumen del proyecto

Se construyó un sistema completo de clasificación binaria de imágenes de gatos y perros. El flujo incluye validación de imágenes, partición estratificada 80/10/10, aumento de datos, entrenamiento de MobileNetV2, experimentos con una CNN académica, evaluación sobre test, API FastAPI, interfaz web y monitoreo.

El dataset examinado contiene 24998 archivos, de los cuales 24997 resultaron válidos y 1 inválidos. Los inválidos se descartaron lógicamente sin borrar ni modificar archivos de PetImages/.

2. Datos y preprocesamiento

Semilla fija: **42**. Selección: hasta 3000 imágenes válidas por clase. Particiones: entrenamiento = 4800, validación = 600, prueba = 600.

- Etiquetas: gato = 0, perro = 1.
- Redimensionado a 224×224×3 y normalización a [0,1] una sola vez.
- Aumento solo en entrenamiento: rotación ≤ 20°, volteo horizontal, desplazamientos horizontal y vertical y zoom.
- Pipeline tf.data con cache(), batch(32) y prefetch().
- Partición estratificada y sin solapamiento entre conjuntos.

Clase	Examinadas	Válidas	Inválidas
Cat	12499	12498	1
Dog	12499	12499	0

3. Arquitectura del modelo de producción

- Base: MobileNetV2 preentrenada en ImageNet, include_top=False, congelada.
- Cabeza: GlobalAveragePooling2D → Dense(128, ReLU) → Dropout(0.5) → Dense(1, sigmoid).
- Optimizador: Adam con learning rate 0.0001.
- Pérdida: binary crossentropy. Métricas: accuracy, precision y recall.
- Máximo 5 épocas; EarlyStopping con paciencia 2 y restauración de los mejores pesos.
- Sin fine-tuning.
- La normalización se aplica en el pipeline tf.data; el modelo no normaliza de nuevo.

Configuración registrada: batch = 32, entrada = [224, 224], épocas máximas = 5.

4. Arquitectura de la CNN académica

- Conv2D de 32 filtros, kernel 3×3, padding same, activación ReLU.
- MaxPooling2D de 2×2.
- Conv2D de 64 filtros, kernel 3×3, ReLU, seguida de MaxPooling2D 2×2.
- Conv2D de 128 filtros, kernel 3×3, ReLU, seguida de MaxPooling2D 2×2.
- Flatten → Dense(64, ReLU) → Dropout opcional (0.5) → Dense(2, softmax).
- Parámetros de la CNN académica: 1273090.
- Entrada de los experimentos: 96×96×3 (reducción por límites de cómputo).

• Pérdida: categorical crossentropy.

5. Proceso de entrenamiento

El modelo de producción se entrenó durante **5 épocas** en **559.15 segundos**. La mejor época según val_loss fue la **5**, con val_loss = 0.0429 y val_accuracy = 0.9867.

Época	Loss train	Loss val	Acc train	Acc val	Precision val	Recall val
1	0.2506	0.0816	0.9013	0.9750	0.9766	0.9733
2	0.1157	0.0554	0.9550	0.9800	0.9800	0.9800
3	0.1042	0.0496	0.9617	0.9833	0.9801	0.9867
4	0.0878	0.0466	0.9654	0.9817	0.9801	0.9833
5	0.0912	0.0429	0.9660	0.9867	0.9834	0.9900

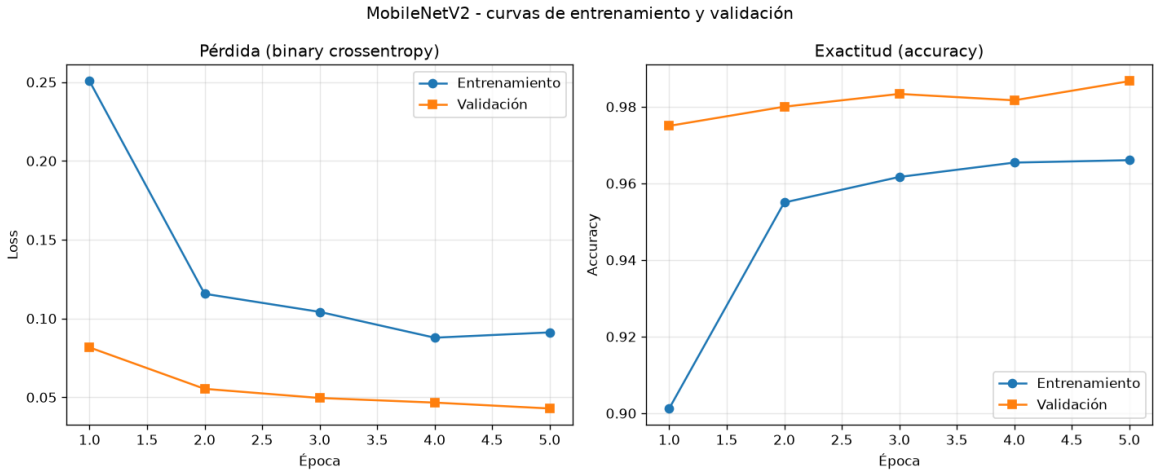


Figura 1. Curvas de pérdida y accuracy de entrenamiento frente a validación.

6. Evaluación final sobre el conjunto de prueba

Se evaluaron **600** imágenes de prueba con umbral 0.5 (positivo = perro). Accuracy = **0.9733**, precision = **0.9641**, recall = **0.9833**, F1 = **0.9736** y AUC = **0.9967**.

Fórmula y cálculo de accuracy

accuracy = (VP + VN) / (VP + VN + FP + FN)

accuracy = (295 + 289) / (295 + 289 + 11 + 5) = 584 / 600 = **0.9733**

Tiempo de inferencia

Medición sobre 100 imágenes individuales del conjunto de prueba, tras un calentamiento de 3 llamadas, en CPU. Media = **166.48 ms**, mediana = 162.14 ms, p95 = 220.23 ms (mín. 103.97 ms, máx. 244.71 ms).

Objetivo accuracy ≥ 92 %: CUMPLIDO. **Objetivo latencia media < 200 ms:** CUMPLIDO.

Métrica	Valor
Accuracy	0.9733
Precision	0.9641
Recall	0.9833

F1	0.9736
AUC	0.9967
Latencia media (ms)	166.48

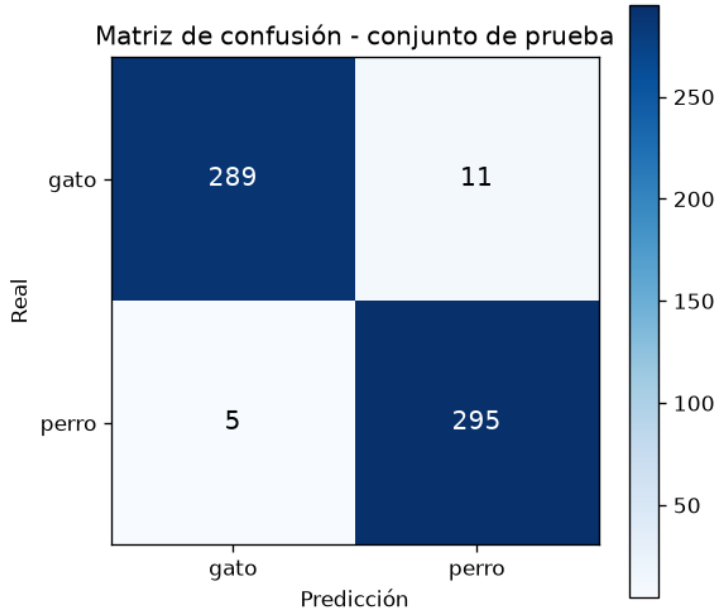


Figura 2. Matriz de confusión sobre el conjunto de prueba.

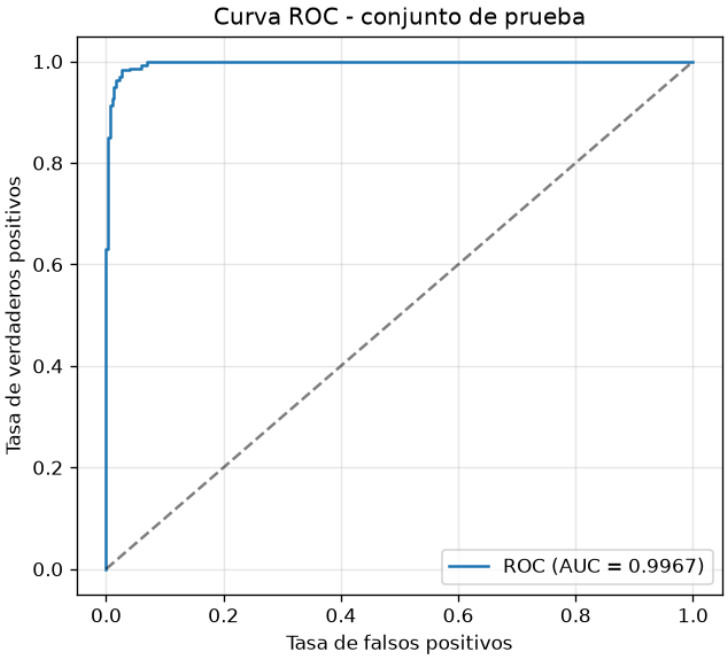


Figura 3. Curva ROC y AUC sobre el conjunto de prueba.

7. Experimentos comparativos

La CNN académica se entrenó con 5 épocas por configuración sobre un subconjunto reproducible y entrada de 96×96. La tabla contiene únicamente resultados de ejecuciones reales.

Experimento	Dropout	Optim.	Aumento	Épocas	Acc train	Acc val	Duración (s)
exp1_adam_dropout_aumento	0.5	adam	Sí	5	0.6180	0.6283	27.92
exp2_adam_sin_dropout_aumento	0.0	adam	Sí	5	0.6927	0.7217	28.62
exp3_sgd_dropout_aumento	0.5	sgd	Sí	5	0.5407	0.5917	26.78
exp4_adam_dropout_sin_aumento	0.5	adam	No	5	0.6240	0.6583	27.38
exp5_sgd_sin_dropout_sin_aumento	0.0	sgd	No	5	0.6250	0.6433	25.81

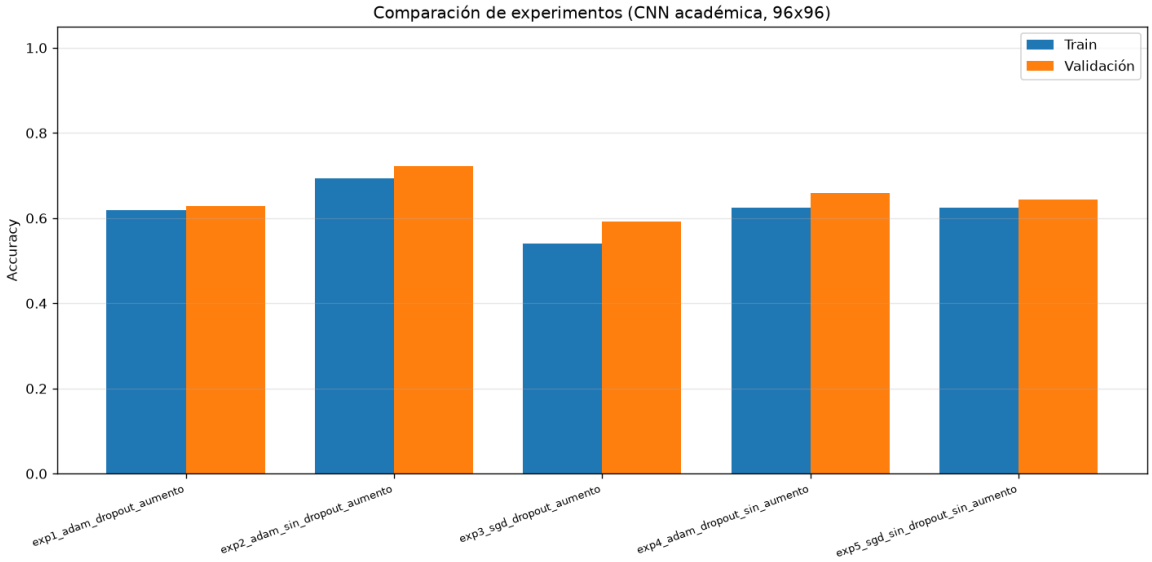


Figura 4. Comparación de accuracy de entrenamiento y validación por experimento.

Análisis de los pares comparables

- Dropout (Adam + aumento): con Dropout val_accuracy = 0.6283; sin Dropout = 0.7217; diferencia = -0.0933.
- Optimizador (Dropout + aumento): Adam val_accuracy = 0.6283; SGD = 0.5917; diferencia = +0.0367.
- Aumento (Adam + Dropout): con aumento val_accuracy = 0.6283; sin aumento = 0.6583; diferencia = -0.0300.

La mejor val_accuracy observada fue **0.7217** en **exp2_adam_sin_dropout_aumento**. Estas diferencias corresponden a una sola ejecución por configuración; no se realizó validación cruzada ni pruebas de significancia estadística, por lo que deben interpretarse como observaciones descriptivas.

8. Análisis de overfitting

Resultados observados

- Accuracy final de entrenamiento: 0.9660.
- Accuracy final de validación: 0.9867.
- Brecha train – validación en la última época: -0.0206.

- Mejor val_loss: 0.0429; val_loss final: 0.0429.

Interpretación

La brecha es inferior a 0.05, por lo que con estos datos no se aprecia un sobreajuste severo. Esto no descarta sobreajuste leve ni garantiza generalización a dominios distintos.

Los experimentos académicos usan un subconjunto y 96×96, por lo que sus resultados no son directamente comparables con el modelo de producción.

9. Conclusiones

- El modelo de producción obtuvo accuracy = 0.9733 y AUC = 0.9967 sobre 600 imágenes de prueba.
- El objetivo de accuracy ≥ 92 % se cumplió.
- El objetivo de latencia media < 200 ms se cumplió (media observada: 166.48 ms en CPU).
- La comparación de Dropout, Adam/SGD y aumento de datos se realizó con una CNN independiente y un subconjunto acotado; sus conclusiones son descriptivas.

10. Limitaciones

- Entrenamiento acotado a 5 épocas y hasta 3000 imágenes por clase.
- Posibles etiquetas erróneas en el dataset original (no se auditó manualmente cada imagen).
- Los experimentos académicos usan 96×96 y un subconjunto por límites de cómputo.
- Ejecución en CPU; los tiempos de inferencia dependen del hardware.
- Una sola ejecución por configuración; sin validación cruzada ni pruebas de significancia.
- No se implementaron Docker, Grad-CAM, pytest, fine-tuning ni detección de drift.